

Домашнее задание №1

Допущения:

- 1 MAC = 2 FLOPS. MaxPool и ReLU 1 FLOPS не входят
 - Память не освобождается. Сумма ~~всех~~ весов и всех активаций ~~сетей~~ ^{сетей} в байтах.
 - Время: один максимум на всю сеть, общ. коэф. +
 - Энергия: гигаут всей GPU за один проход.
- Коэф. подбора по размерам на Т4.

FLOPS

Свертка: $2B \cdot C_{out} \cdot H \cdot W \cdot K^2 \cdot C_{in}$

Линейный: $2B \cdot C_{in} \cdot C_{out} + B \cdot C_{out}$

Слой	H=W	FLOPS
Conv 7x7, S2, 3-32	S/2	$2352 \cdot B \cdot S^2$
Conv 5x5, 32-64	S/4	$6400 \cdot B \cdot S^2$
Conv 3x3, S2, 64-128	S/8	$2304 \cdot B \cdot S^2$
Conv 3x3, S2, 256-256	S/16	$4608 \cdot B \cdot S^2$
Conv 1x1, 128-256	S/8	$1024 \cdot B \cdot S^2$
Conv 1x1, 256-512	S/16	$1024 \cdot B \cdot S^2$
Linear 512-256, 256-100	-	$313700 \cdot B$

$$FLOPS(S, B) = B \cdot (17712 \cdot S^2 + 313700)$$

Требный прогон Т4 (S, B=64, 8) - FLOPS = $5,829 \cdot 10^8$, как с ячеек

Меморй

4 байта на число, все в памяти
От Θ не зависит

$$\begin{aligned}\text{Параметры} &= 3 \cdot 32 \cdot 49 = 4704 \\ &32 \cdot 64 \cdot 25 = 51200 \\ &64 \cdot 128 \cdot 9 = 73728 \\ &128 \cdot 256 = 32768 \\ &256 \cdot 256 \cdot 9 = 589824 \\ &256 \cdot 512 = 131072 \\ &512 \cdot 256 + 256 = 131328 \\ &256 \cdot 100 + 100 = 25700\end{aligned}$$

$$1040324 \cdot 4 \text{ байт} =$$

$$= 4161296 \text{ байт}$$

~~Вход = 3 BS²~~

$$\text{Вход} = 3 BS^2$$

$$\text{Выход} = \text{conv } 7 \times 7: B \cdot 32 \cdot \left(\frac{S}{2}\right)^2 = 8 \cdot B \cdot S^2 \int \cdot 4 \text{ байт} = 44 BS^2 - \text{это}$$

мк, дальше не
показываю цифры

$$\text{Меморй}(S, B) = 4161296 + 44 BS^2$$

Bytes

Каждый слой читает ^{вход} и пишет выход, линейный еще
читает веса.

~~Размеры:~~
Размеры: вход $3 BS^2$, conv 7×7 $8 BS^2$, Pool $2 BS^2$, conv 5×5 $4 BS^2$,
conv 3×3 $2 BS^2$, conv 1×1 $4 BS^2$, conv 3×3 BS^2 , conv 1×1 $2 BS^2$

Элементов активации проходит через слой $91 BS^2 \cdot 4 \text{ байт}$

Глобал от S не зависит. Global avg Pool = $512 B$, Linear = $512 B +$
 $+ 256 B$, ReLU = $2 \cdot 256 B$, Linear = $256 B + 100 B$. Сумма $2148 B \cdot 4 \text{ байт}$

$$\text{Bytes}(S, B) = 364 BS^2 + 2592 B + 4161296$$

Latency (S, B, Θ)

К работе модели добавляется запуск эмер T_0

$$C_{\text{смет}} = \frac{FLOPs}{c} \quad \text{Пересылка} = \frac{\text{Bytes}}{w}$$

c и w от S и B не зависят

$$C_{\text{смет}} = \frac{B(17712S^2 + 313700)}{c} \quad \text{Память} = \frac{364BS^2 + 8592B + 416196}{w}$$

c - скорость счета

w - скорость памяти

Смет и пересылка идут так, что идет более ~~костя~~ долгая (не складываем)

$$\text{Latency}(S, B, \Theta) = T_0 + \max(\text{смет}, \text{память})$$

$$\Theta = (T_0, c, w)$$

$$T_4: T_0 = 4,48 \cdot 10^{-4} \text{ c}; \quad c = 3,76 \cdot 10^{12} \text{ FLOP/c}; \quad w = 9,08 \cdot 10^{10} \text{ байт/c}$$

Energy (S, B, Θ_E)

Энергия равна пот. мощности, умн. на время модели + ~~в~~ на операцию + энергия на переданный байт

P, e_F, e_B постоянны

$$\Theta_E = (P, e_F, e_B, T_0, c, w)$$

$$\text{Energy}(S, B, \Theta_E) = P \cdot \text{Latency}(S, B, \Theta) + e_F \cdot FLOPs(S, B) + e_B \cdot \text{Bytes}(S, B)$$

$$T_4: P = 69,1 \text{ Вт}, \quad e_F = 2,13 \cdot 10^{-12} \text{ Дж/FLOP}, \quad e_B = 1,38 \cdot 10^{-18} \text{ Дж/байт}$$