Super-Convergence: Very Fast Training of Neural Networks Using Large Learning Rates

Разбор статьи для Efficient NN

Головкин Иван

Почему обычное обучение долгое

1. Стандарт для ResNet на CIFAR - ступенчатый learning rate
2. Долго держат шаг около 0.1-0.35, пока точность не выйдет на плато
3. Потом делят шаг на 10 и снова ждут полку
4. Для ResNet-56 это 80 000 итераций и около 91.2% - по проверке исследователей (бейзлайн)
5. Большую часть времени сидим на полке и почти не улучшаемся
6. Верхнюю границу шага берут «как обычно», не проверяя, какой большой шаг сеть ещё переносит

Гипотеза статьи

1. Сначала измерить, до какого learning rate точность ещё держится
2. Если обвала нет, поставить один треугольный цикл до этой границы
3. В начале шаг маленький, в середине очень большой, в конце снова маленький
4. Ожидание: та же или более высокая точность за 10 000 итераций вместо 80 000

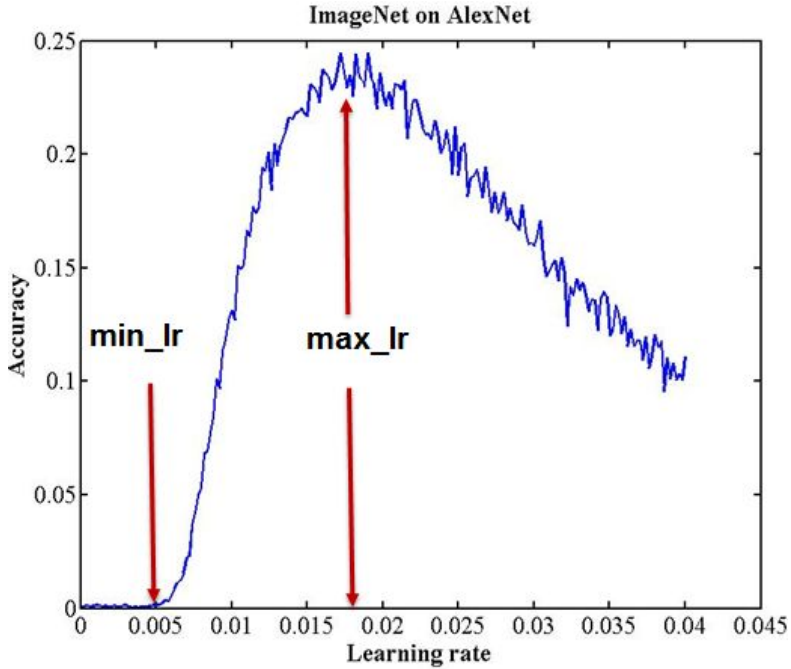
Ожидаемый результат - знание о том, что LR можно ставить выше и получать схожую точность за меньший промежуток времени

Методы исследования гипотезы

1. Гипотеза: один цикл 0.1 - 3.0 - 0.1 догоняет ступенчатое обучение и делает это в 8 раз короче
2. Контроль: piecewise, learning rate 0.35, деление на 10 на итерациях 50 000 и 70 000, всего 80 000 итераций
3. Проверка: triangular CLR, stepsize 5 000, всего 10 000 итераций
4. Сеть и данные одни и те же: ResNet-56, CIFAR-10
5. Метрика: test accuracy на всех 10 000 тестовых картинках
6. Отдельный прогон, LR range test, отвечает на вопрос, почему верх цикла равен 3

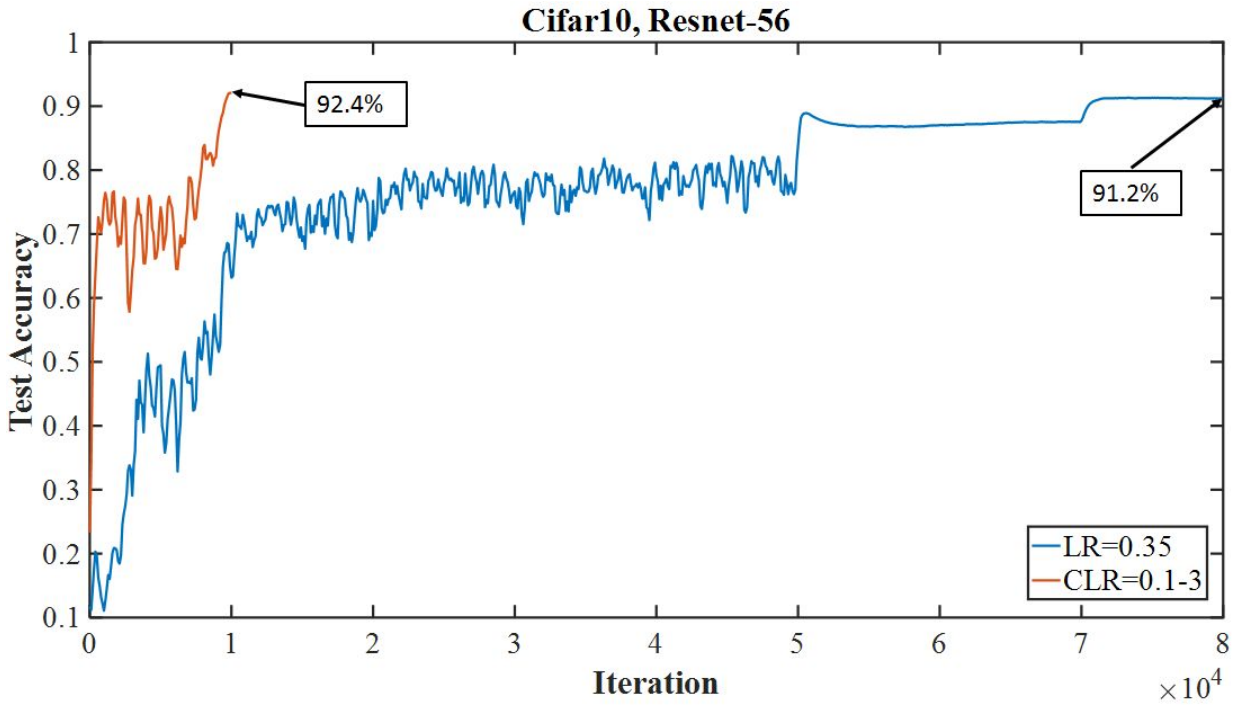
Выбор границ цикла

- LR range test: learning rate линейно растёт от почти нуля до большого значения
- На графике test accuracy против learning rate
- Обычная кривая имеет пик: до пика сеть учится, после пика шаг уже слишком большой
- max_lr ставят в район пика, base_lr берут в 3-4 раза меньше
- Рисунок из статьи: типичный range test с явным пиком



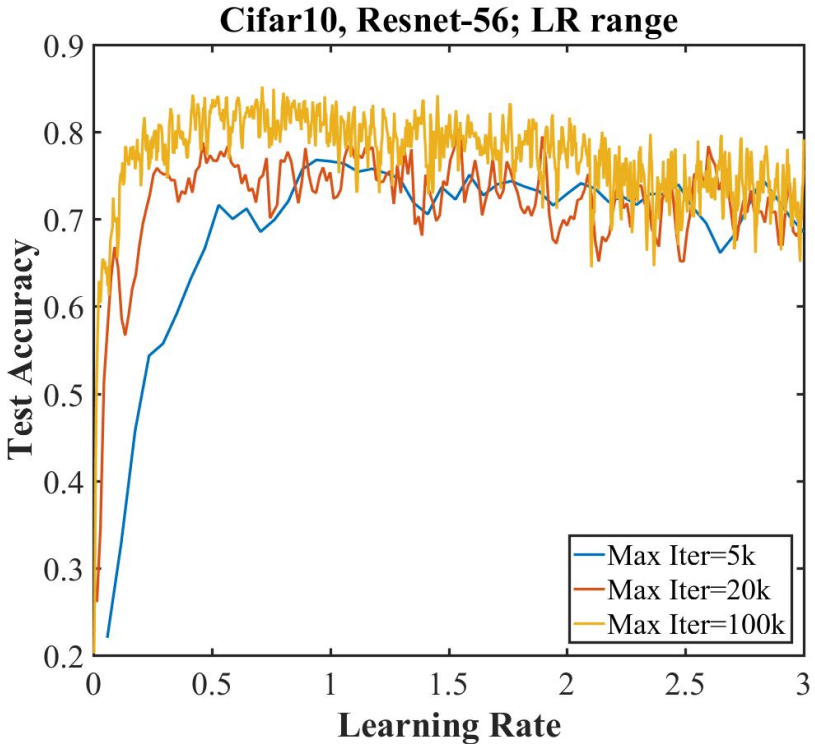
Результаты

Оранжевый цикл доходит до 92.4% за 10 000 итераций, синий ступенчатый режим — до 91.2% за 80 000



Range test

У ResNet-56 нет пика и обвала, точность держится примерно на 70–85% вплоть до learning rate 3



Выводы

- Гипотеза подтверждается: один цикл с learning rate до 3 доходит до точности длинного обучения
- Итераций достаточно в 8 раз меньше, 10 000 против 80 000
- У нас 92.31% против 91.99%, в статье 92.4% против 91.2% - подтвердил своим прогоном в отчете
- Range test объясняет выбор границы: при learning rate 3 обвала к 10% нет
- Число 92.4% привязано к batch 1000. При batch 125 тот же цикл даёт 85.08% - моя проверка показала такой результат, при меньшем батче точность упала. Хоть авторы этот батч не проверяли, но не скрывают, что на меньших батчах точность будет ниже

Обобщаю правила

- Перед длинным обучением сделать LR range test
- Если точность держится до необычно большого шага, super-convergence для этой сети доступна
- Поставить один цикл: base_lr в 3-4 раза ниже найденной границы, max_lr на этой границе
- Шаг растёт линейно половину цикла и так же линейно падает
- Длину цикла взять порядка нескольких тысяч–десятков тысяч итераций, не следовать десяткам-сотням тысяч
- С большим шагом ослабить другую регуляризацию: увеличить батч, не добавлять лишний dropout и слишком большой weight decay
- Для короткого прогона уменьшить moving_average_fraction BatchNorm, чтобы статистика успела обновиться